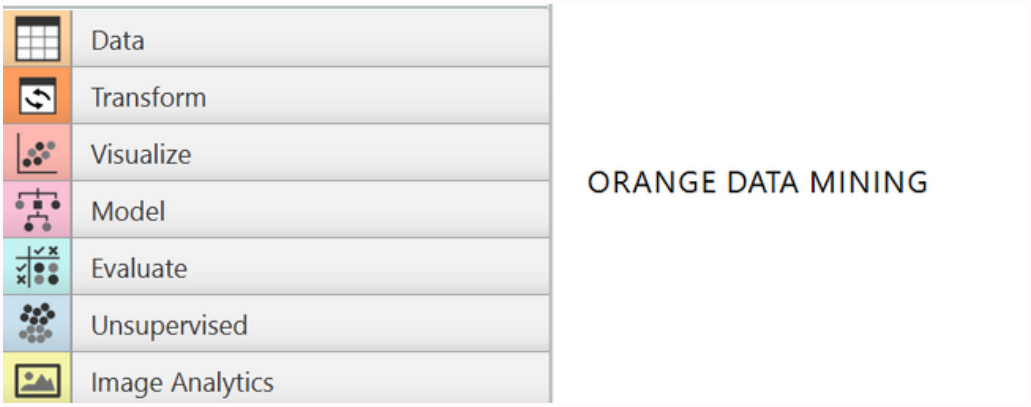
RAPPORT DE PROJET - TE34MI



CLASSIFICATION SUPERVISÉE ET NON SUPERVISÉE POUR L'ANALYSE DE PREFERENCES DE TRAVAIL ET DE PRODUITS COSMÉTIQUES

PROJET RÉALISÉ PAR

Kawthar BOUGUIMA 22303487

PROJET ENCADRÉ PAR

Nefissa KHIARI

CONTEXTE GÉNERAL

Ce projet a pour objectif de mettre en œuvre deux chaînes complètes de traitement en apprentissage supervisé et apprentissage non supervisé, à partir de deux jeux de données distincts.
Dans un premier temps, une analyse non supervisée a été menée sur un jeu de données textuel portant sur des avis de produits cosmétiques
L'objectif de cette première partie est d'identifier des groupes d'avis similaires sans étiquettes préexistantes, à l'aide de techniques de preprocessing textuel et de clustering.
Dans un second temps, une analyse supervisée a été réalisée sur un jeu de données issu d'une enquête portant sur les conditions de travail (télétravail vs travail au bureau).
L'objectif est de prédire si une personne préfère travailler en remote ou en office, à partir de variables socio-professionnelles et comportementales.
Une chaîne complète de classification a été mise en place, comprenant sélection des données, séparation apprentissage/test, apprentissage de plusieurs modèles et évaluation comparative.
L'ensemble des analyses, visualisations, prétraitements et classifications ont été réalisés à l'aide du logiciel de Data Mining Orange, qui permet une construction visuelle des chaines de traitement ainsi qu'une interprétation intuitive des résultats.

I. Apprentissage Non supervisé

1.1 Jeu de données 3
1.2 Chaîne de traitement 4
1.3 Interprétation 10

II. Apprentissage supervisé

2.1 Jeu de données 13
2.2 Chaîne de traitement 15
2.3 Interprétation 20

1. Apprentissage non supervisé

1.1 Jeu de données

Description générale :
Le jeu de données choisi provient du site Kaggle (dataset : NLP Ulta Skincare Reviews). Il regroupe des avis clients rédigés sur le site Ulta Beauty, un détaillant américain de produits cosmétiques et de soins de la peau.
Chaque ligne correspond à un avis utilisateur concernant un produit de beauté spécifique.

Objectif de l'analyse :
Mettre en œuvre une chaîne d'apprentissage non supervisé pour identifier des groupes d'avis similaires en fonction de leur contenu textuel, sans étiquettes préexistantes.

Chaque individu correspond à un avis textuel d'un utilisateur.

Variable	Description de la variable	Type de la variable
Product	Nom du produit commenté	Qualitative nominale
Review_text	Contenu de l'avis rédigé par l'utilisateur	Qualitative textuelle

Tableau descriptif de chacune des variables du jeu de données

Constitution du jeu de données :
Le fichier a été téléchargé sur Kaggle via le lien :
https://www.kaggle.com/datasets/nenamalikah/nlp-ulta-skincare-reviews
Le dataset initial contient plus de 2 000 avis.
Pour garantir une interprétation qualitative, un échantillon de 100 avis a été extrait aléatoirement à l'aide d'Orange.
Cet échantillon est suffisant pour observer des regroupements pertinents tout en restant lisible graphiquement.

1. Apprentissage non supervisé

1.2 Chaîne de traitement : Nettoyage et prétraitement

Visualisation initiale du dataset
La première étape a consisté à importer le fichier CSV via le widget File.
Nous avons ensuite utilisé le widget Data Table pour visualiser toutes les variables telles qu'elles apparaissaient dans le fichier d'origine. Cela permet de repérer les colonnes pertinentes et les éventuelles valeurs manquantes ou incohérentes.

Info
4150 instances
7 features (no missing values)
Data has no target variable.
3 meta attributes

Columns (Double click to edit)

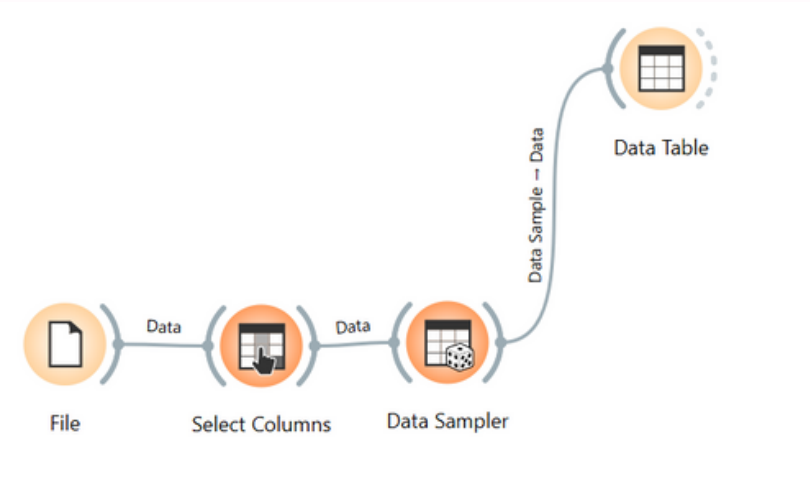
	Name	Type	Role	Values
1	Verified_Buyer	C categorical	feature	No, Yes
2	Review_Date	C categorical	feature	1 month ago, 1 year ago, 2 months ago, 2 ...
3	Review_Upvotes	N numeric	feature	
4	Review_Downv...	N numeric	feature	
5	Product	C categorical	feature	Daily Microfoliant, Daily Superfoliant, Hydro ...
6	Brand	C categorical	feature	Dermalogica
7	Scrape_Date	C categorical	feature	3/27/23
8	Review_Title	S text	meta	
9	Review_Text	S text	meta	
10	Review_Location	S text	meta	

Aperçu des variables dans la fenêtre orange

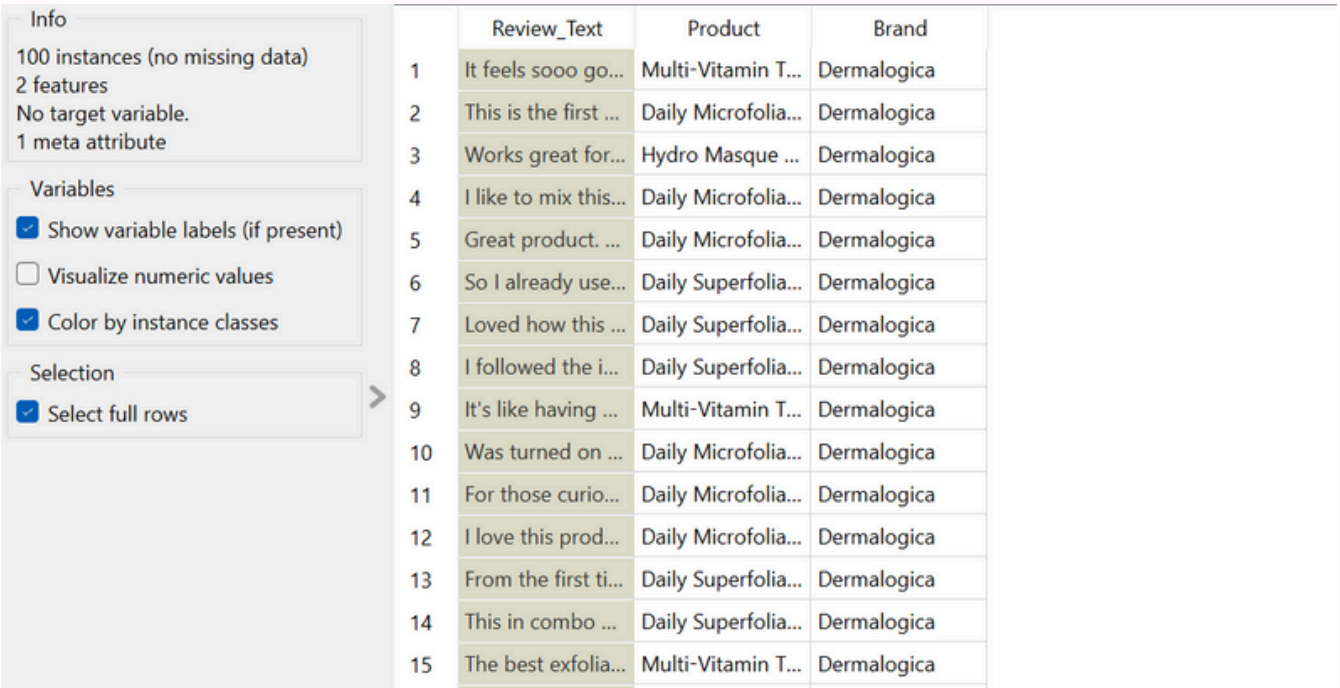
2. Sélection et échantillonnage des données

Comme le dataset initial contient plusieurs milliers d'avis, nous avons appliqué deux étapes dans Orange pour réduire et organiser les données :

1. Select Columns :
   - Nous avons conservé uniquement les colonnes review_text, et product, car ce sont celles pertinentes pour l'analyse non supervisée.
   - Cela permet de se concentrer sur le texte tout en gardant des informations secondaires pour l'interprétation des clusters.
2. Data Sampler :
   - Nous avons extrait un échantillon aléatoire de 100 avis afin de faciliter la visualisation et l'interprétation des résultats dans les étapes suivantes.



Chaine de traitement de nettoyage orange

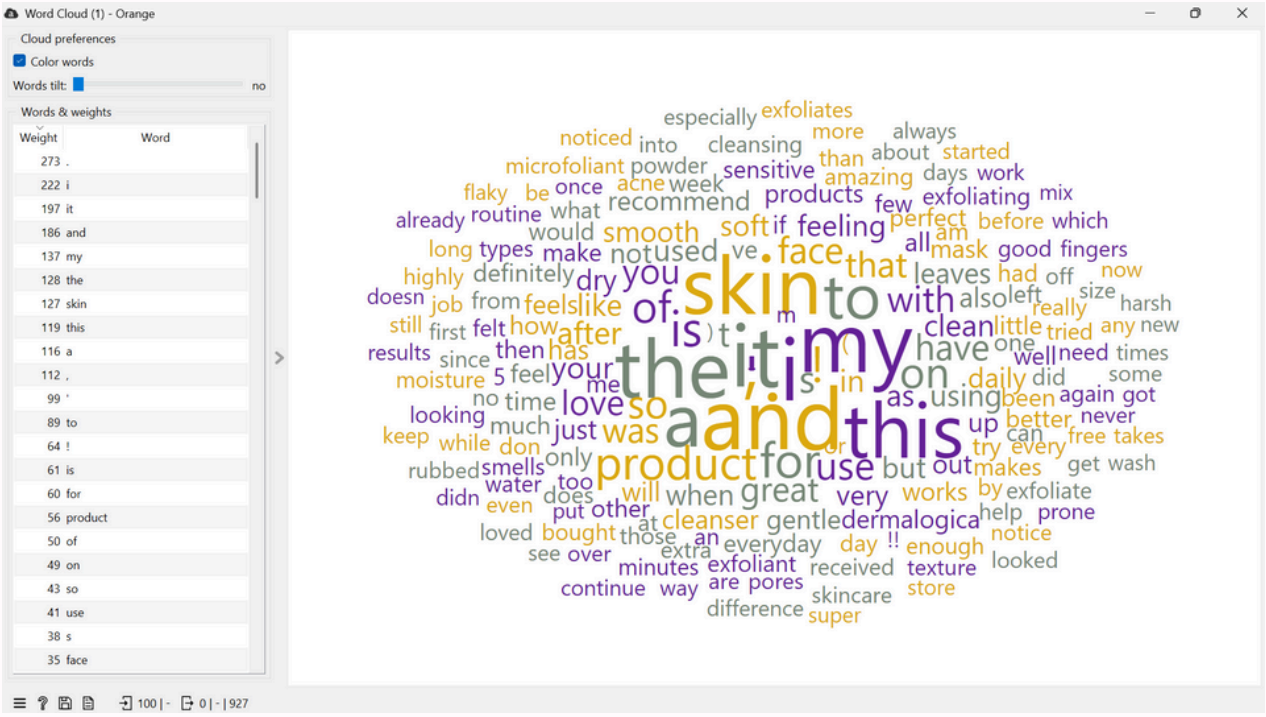


	Review_Text	Product	Brand
1	It feels sooo go...	Multi-Vitamin T...	Dermalogica
2	This is the first ...	Daily Microfolia...	Dermalogica
3	Works great for...	Hydro Masque ...	Dermalogica
4	I like to mix this...	Daily Microfolia...	Dermalogica
5	Great product. ...	Daily Microfolia...	Dermalogica
6	So I already use...	Daily Superfolia...	Dermalogica
7	Loved how this ...	Daily Superfolia...	Dermalogica
8	I followed the i...	Daily Superfolia...	Dermalogica
9	It's like having ...	Multi-Vitamin T...	Dermalogica
10	Was turned on ...	Daily Microfolia...	Dermalogica
11	For those curio...	Daily Microfolia...	Dermalogica
12	I love this prod...	Daily Microfolia...	Dermalogica
13	From the first ti...	Daily Superfolia...	Dermalogica
14	This in combo ...	Daily Superfolia...	Dermalogica
15	The best exfolia...	Multi-Vitamin T...	Dermalogica

Aperçu de la data table nettoyée

3. Exploration du contenu textuel (Corpus et premier nuage de mots)
Ensuite, nous avons créé un Corpus à partir de la colonne review_text.

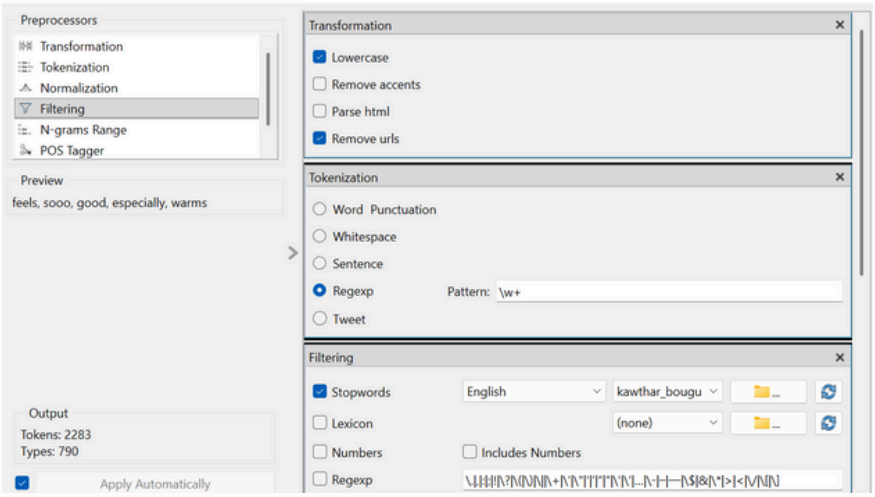
- Le corpus permet de transformer le texte en format manipulable par Orange.
- À ce stade, nous avons généré un premier Word Cloud pour visualiser les mots les plus fréquents sans aucun prétraitement.



Nuage de mots, non trié, montrant l'état brut du texte.

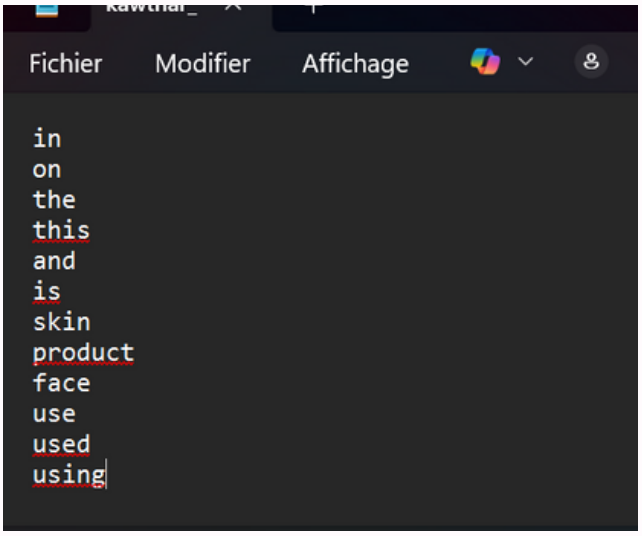
4. Prétraitement du texte
Le prétraitement a été réalisé avec le widget Preprocess Text et comprend plusieurs étapes :

1. Normalisation :
   - Conversion en minuscules, suppression de la ponctuation.

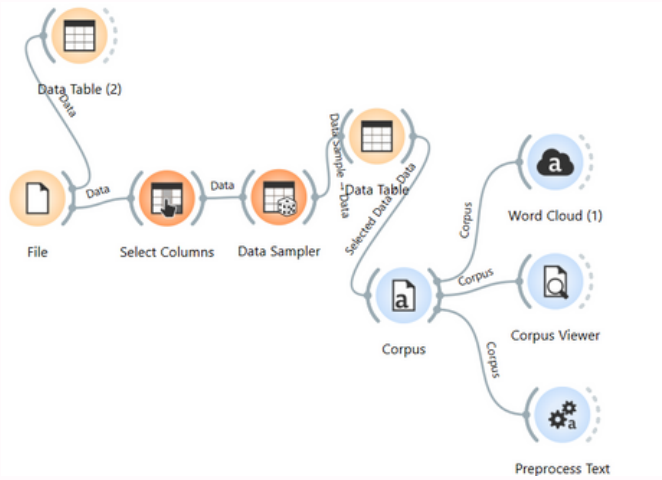


Aperçu de la fenêtre pré-processing

- Filtrage des mots :
  - Suppression des stopwords (mots très fréquents mais peu informatifs comme “the”, “and”).
  - Nous avons également ajouté manuellement des mots peu pertinents pour notre analyse, tels que “skin”, “product”, “face”, “use”, “used”, “using”, car ils apparaissaient très fréquemment et ne permettaient pas de distinguer les avis.



Aperçu du fichier stopwords



Pipeline de prétraitement

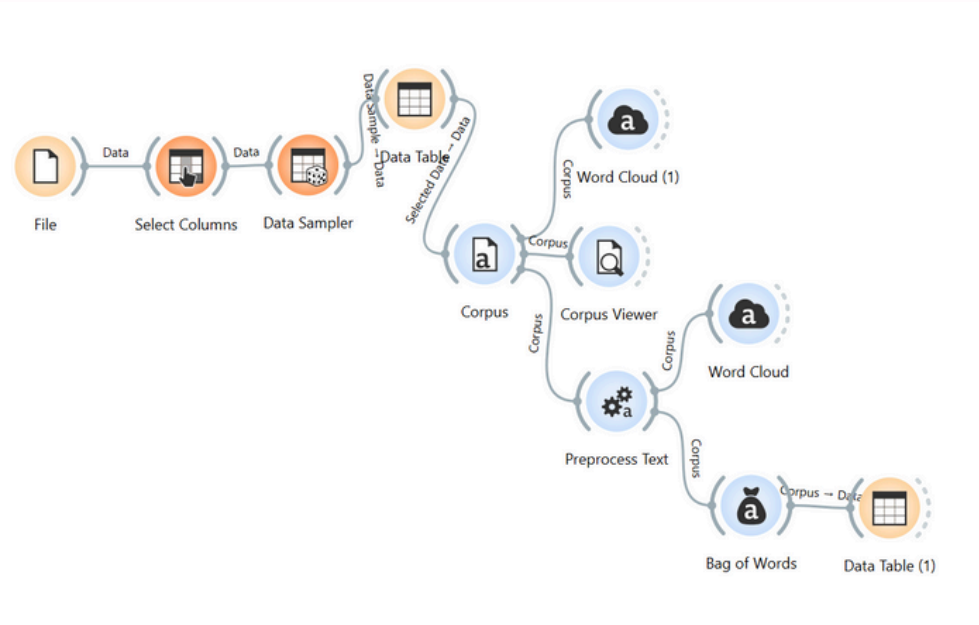


Nuage de mots, “trié”

- Lemmatisation : réduction des mots à leur forme racine (ex. “moisturizes” → “moisturize”).
- Vectorisation Bag of Words : Transformation du texte en vecteurs numériques pondérés selon la fréquence des mots dans le document par rapport au corpus.

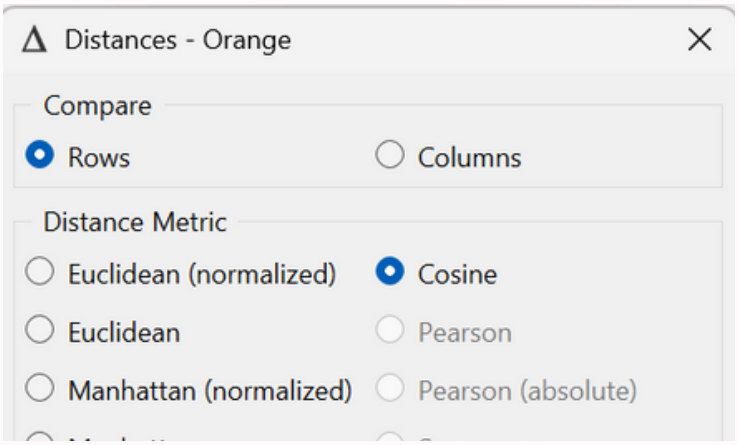
1.2 Chaîne de traitement : Clustering

Après le prétraitement, nous avons utilisé le widget Bag of Words afin de transformer le corpus nettoyé en matrice documents × termes.
Chaque avis y est représenté selon les mots qu'il contient et leur importance pondérée.
Le Bag of Words est indispensable pour la suite, car c'est à partir de cette matrice que l'on calcule une distance entre les avis et que l'on réalise le clustering.



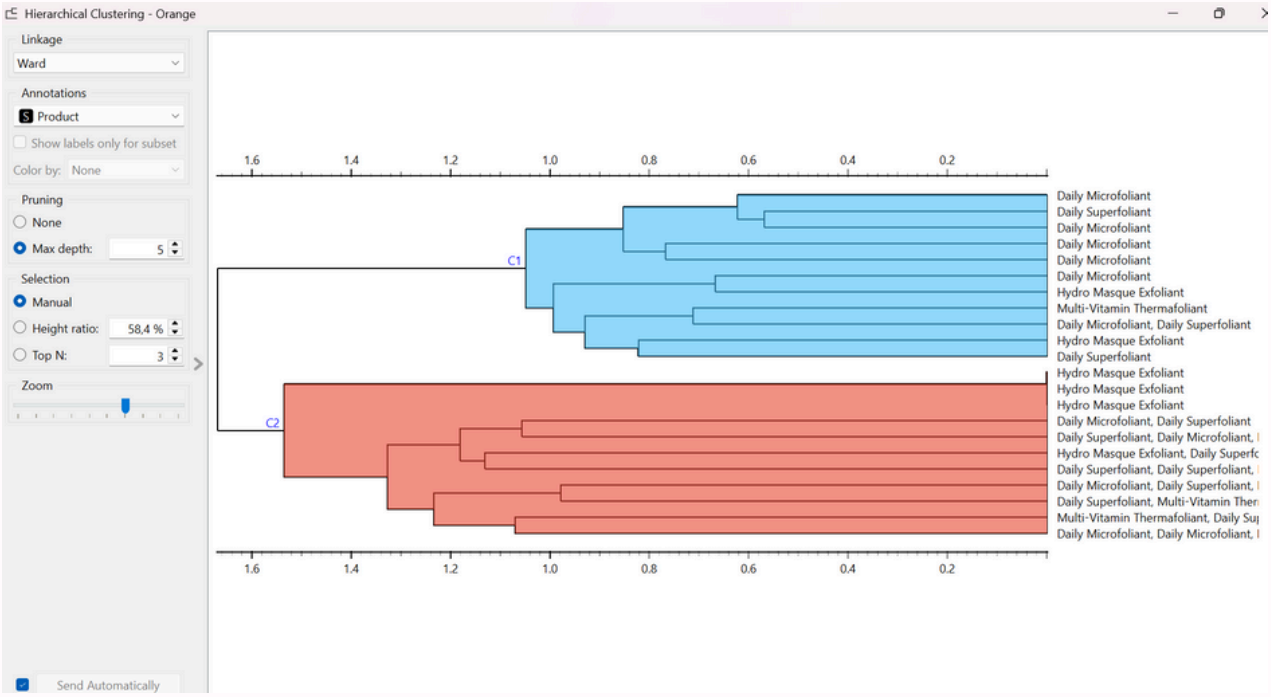
Chaine de traitement avec widget Bag of words

Nous avons ensuite appliqué une distance Cosine sur cette matrice, c'est la distance la plus adaptée pour comparer des textes vectorisés : elle mesure la similarité entre les listes de mots, indépendamment de la longueur des avis. Elle permet donc de regrouper les avis qui utilisent des termes proches, même si les textes ne font pas la même taille.



Fenêtre avec distance "cosine"

Nous avons ensuite appliqué un clustering hiérarchique à l'aide du widget Hierarchical Clustering, avec la méthode Ward.
Ward minimise la variance à l'intérieur des groupes, ce qui donne des clusters plus stables et plus homogènes.
C'est généralement la méthode la plus efficace pour structurer des données textuelles.



Dendrogramme avec coupure visible

D'après la structure du dendrogramme, deux grands groupes se distinguent clairement.

- la coupure naturelle du dendrogramme séparait clairement deux grandes branches cohérentes,
- les groupes obtenus avaient une taille équilibrée,
- les mots dominants dans chaque groupe étaient suffisamment distinctifs.

On connecte ensuite des Word Cloud et l'on peut passer a l'interprétation

1.3 Interprétation

Les mots dominants du Cluster 1 sont :
exfoliant, daily, gentle, soft, leaves, feeling, works, routine, microfoliant, perfect, need, sometimes.
Interprétation du cluster
Ce groupe regroupe majoritairement des avis mettant l'accent sur :

- la douceur du produit ("gentle", "soft"),
- la sensation après utilisation ("feeling", "leaves well"),
- l'intégration dans la routine quotidienne ("daily", "routine", "everyday"),
- des produits exfoliants non agressifs ("microfoliant", "exfoliant").

Il correspond donc clairement à un cluster d'avis décrivant l'expérience sensorielle, la texture et la compatibilité avec un usage quotidien.
Les personnes semblent valoriser un exfoliant doux, adapté aux peaux sensibles et agréable à utiliser régulièrement.
On peut qualifier ce cluster comme :
Cluster 1 = "Expérience douce & usage quotidien"



Nuage de mots du premier cluster : C1

Les mots dominants du second cluster sont :
clean, feels, left, great, little, everyday, water, fingers, rinsed, products, recommend, mask, dry, texture, try, week, rubbed, store.
Interprétation du cluster
Ce second groupe contient des avis beaucoup plus diversifiés et détaillés, mettant l'accent sur :

- le mode d'utilisation concret ("fingers", "rubbed", "water", "wet"),
- les sensations après rinçage ("left clean", "feels great"),
- la texture ("texture", "powder", "smooth"),
- la fréquence d'usage ("everyday", "week"),
- des retours sur les résultats visibles ("brightens", "smells", "breakouts", "dryness"),
- des recommandations explicites ("would recommend", "try", "store").

Il s'agit d'un cluster plus orienté vers l'efficacité perçue, les effets visibles et le ressenti après application.
Les avis y sont également plus longs et détaillés, avec des retours sur :

- le nettoyage,
- les problèmes de peau (sécheresse, acné),
- les performances du produit dans le temps.

On peut qualifier ce cluster comme :
Cluster 2 = "Efficacité, résultats & application pratique"



Nuage de mots du second cluster : C2

Conclusion

La séparation obtenue via le clustering est cohérente et pertinente :

- Le Cluster 1 regroupe des utilisateurs recherchant confort, douceur et sensorialité.
- Le Cluster 2 rassemble ceux cherchant efficacité, résultats visibles ou évaluant l'usage pratique.

Ces résultats montrent que les avis sur des produits cosmétiques se structurent naturellement autour de deux axes majeurs :

1. L'expérience sensorielle / texture / douceur
2. L'efficacité réelle / usage / résultats

Cela valide l'intérêt du clustering hiérarchique sur données textuelles pour faire émerger des thématiques récurrentes dans un corpus d'avis consommateurs.
Ce type d'analyse pourrait être utilisé en marketing pour :

- segmenter les attentes des clients,
- détecter des tendances dans les retours utilisateurs,
- améliorer le positionnement de produits,
- comprendre quelles dimensions (texture vs efficacité) sont les plus importantes selon les publics.

2. Apprentissage supervisé

2.1 Jeu de données

Le jeu de données choisi provient du site Kaggle (dataset : Predict if people prefer WFH vs WFO post Covid-19). Il correspond aux réponses d'un questionnaire portant sur les conditions de travail à distance et en présentiel. Chaque individu représente une personne ayant répondu au sondage, et les différentes colonnes décrivent ses caractéristiques démographiques ainsi que ses perceptions du télétravail.

Objectif de l'analyse :
Mettre en place une chaîne d'apprentissage supervisé permettant de prédire le mode de travail préféré d'un individu (télétravail / travail au bureau) à partir de ses caractéristiques personnelles et de ses réponses.

La variable cible sélectionnée est : (Target) Mode de travail préféré

- 1 → Remote work (télétravail)
- 0 → Office work (travail au bureau)

Constitution du jeu de données :
Le fichier a été téléchargé sur Kaggle via le lien :
https://www.kaggle.com/datasets/anninasimon/predict-if-people-prefer-wfh-verses-wfo-data/data

	Target	Name	Age	Gender	Occupation	kids	RM_save_money	RM_quality_time	RM_better_sleep	RM_lazy
1	1	Bhavana	45	Female	Tutor	Yes	Yes	Yes	Yes	
2	1	Harry	24	Male	Tutor	No	No	No	No	
3	1	Banditaa	53	Female	HR	Yes	Yes	Yes	Yes	
4	0	Neetha	26	Female	Engineer	No	Yes	Yes	No	
5	1	Ram	26	Male	Recruiter	No	No	Yes	No	
6	0	Gaurav	27	Male	Recruiter	No	Yes	Yes	Yes	
7	1	Sandy	24	Male	Engineer	No	No	No	No	
8	0	Gina	36	Female	Engineer	No	No	Yes	No	
9	0	Ray	26	Male	Engineer	No	Yes	Yes	Yes	
10	1	Ganika	26	Female	Recruiter	No	Yes	Yes	Yes	
11	0	Sheetal	27	Female	Engineer	No	Yes	Yes	No	
12	1	Abbas	25	Male	Engineer	No	Yes	Yes	Yes	
13	1	Ishanvi	26	Female	Business	No	Yes	Yes	Yes	
14	0	Ira	25	Female	Business	No	Yes	No	No	
15	0	Sameera	25	Female	Business	No	Yes	Yes	No	

Aperçu de la Data Table Brut

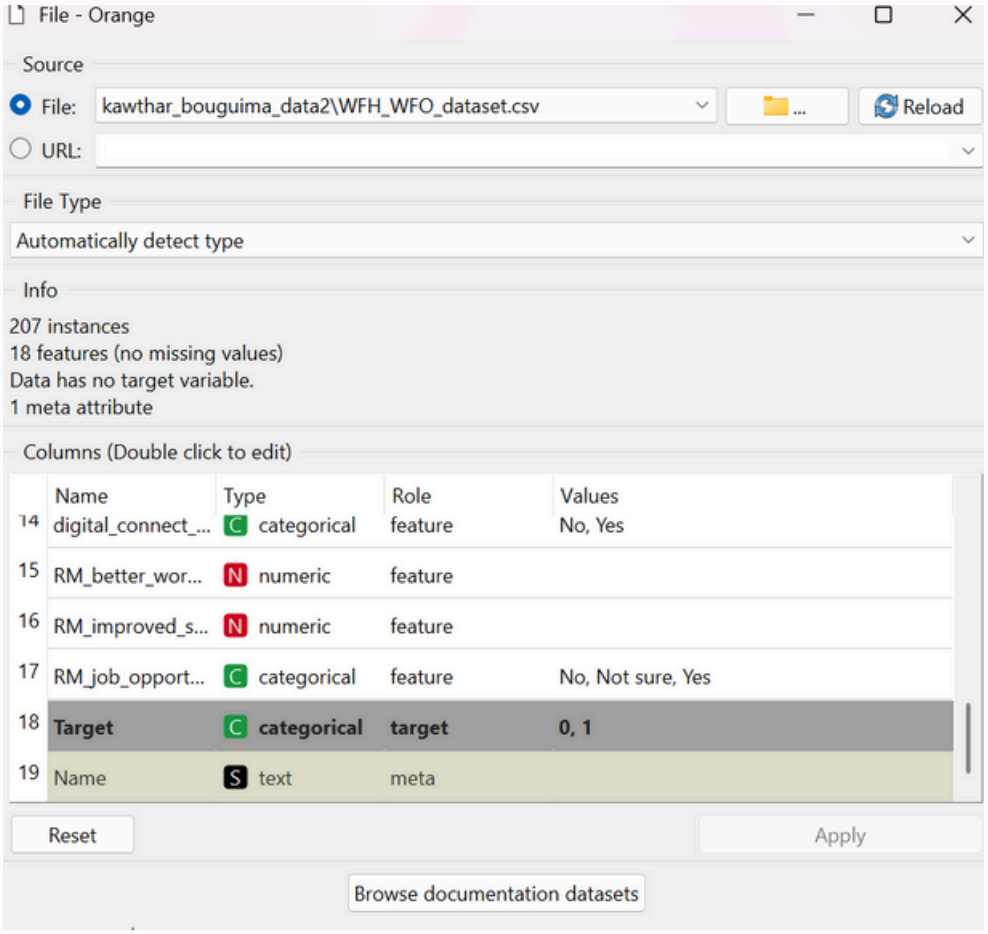
Variable	Description de la variable	Type de la variable
Target	Mode de travail préféré (remote = 1, office = 0)	Qualitative discrète (cible)

Tableau descriptif de chacune des variables du jeu de données

2. Apprentissage supervisé

2.2 Chaîne de traitement : Nettoyage et prétraitement

Visualisation initiale du dataset
La première étape a consisté à importer le fichier CSV via le widget File.
Nous avons ensuite utilisé le widget Data Table pour visualiser toutes les variables telles qu'elles apparaissaient dans le fichier d'origine. Cela permet de repérer les colonnes pertinentes et les éventuelles valeurs manquantes ou incohérentes.



Aperçu des variables dans la fenêtre orange

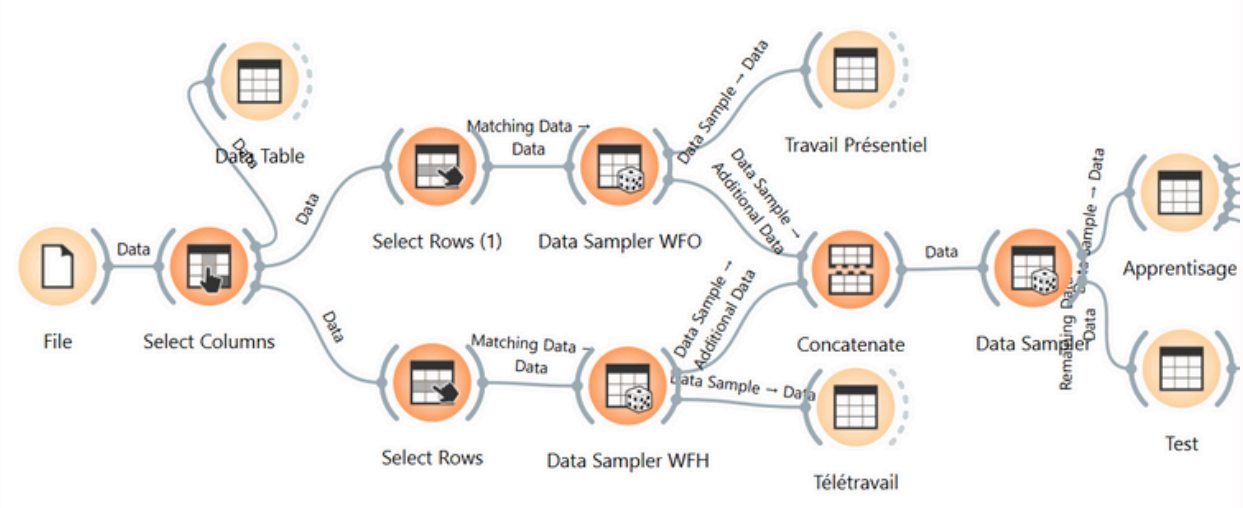
2. Sélection et échantillonnage des données
Le dataset initial contient plus de 206 données

1. Select Columns :

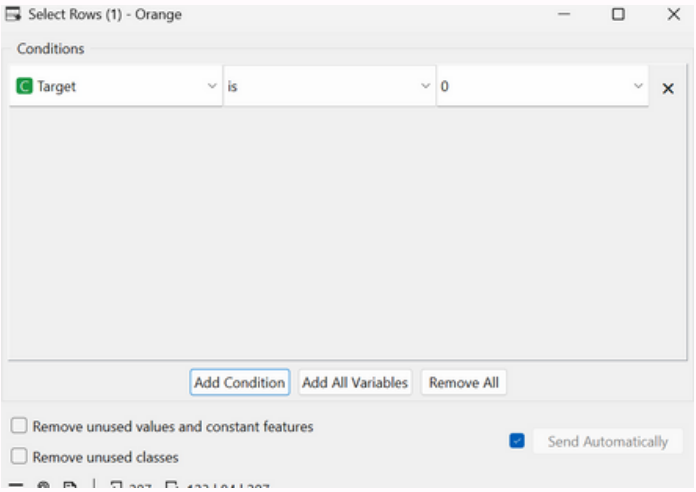
- Nous avons sélectionné uniquement les variables pertinentes, sans valeurs manquantes.

2. Data Sampler :

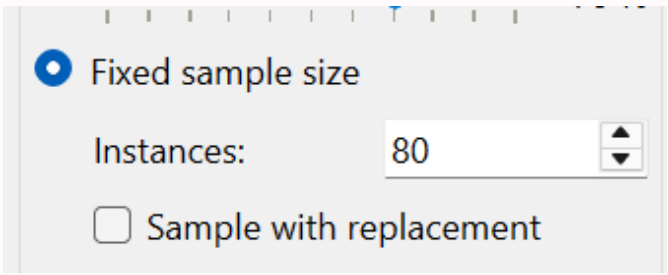
- Nous avons extrait un échantillon aléatoire de 160 avis afin de faciliter la visualisation et l'interprétation des résultats dans les étapes suivantes
  - 80 individus pour la classe 0
  - 80 individus pour la classe 1
  - dont :
  - → 64 × 2 = 128 individus pour l'apprentissage
  - → 16 × 2 = 32 individus pour le test



Aperçu de la pipeline de prétraitement



Séléction des colonnes de la classe 0

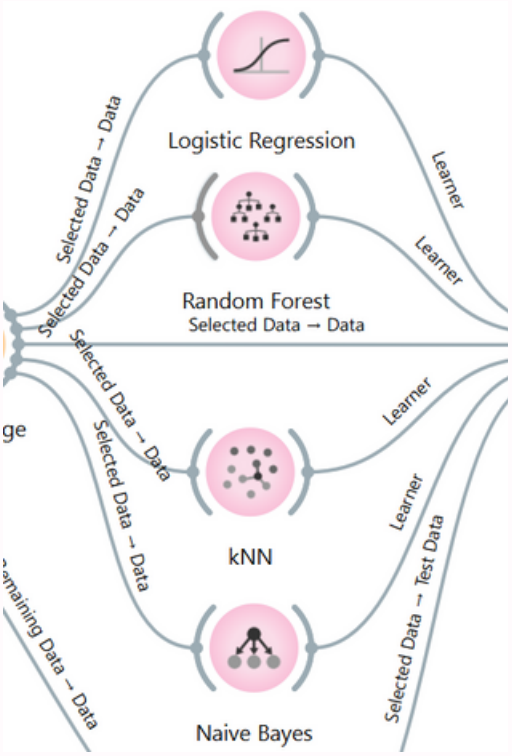


Séléction d'un "sample" de 80

2.2 Chaîne de traitement : Classification

Après le prétraitement, nous avons testé plusieurs modèles classiques pour la classification supervisée :

- Logistic Regression
- Random Forest
- k-Nearest Neighbors (simple et basé sur distance)
- Naive Bayes (adapté aux variables catégorielles)

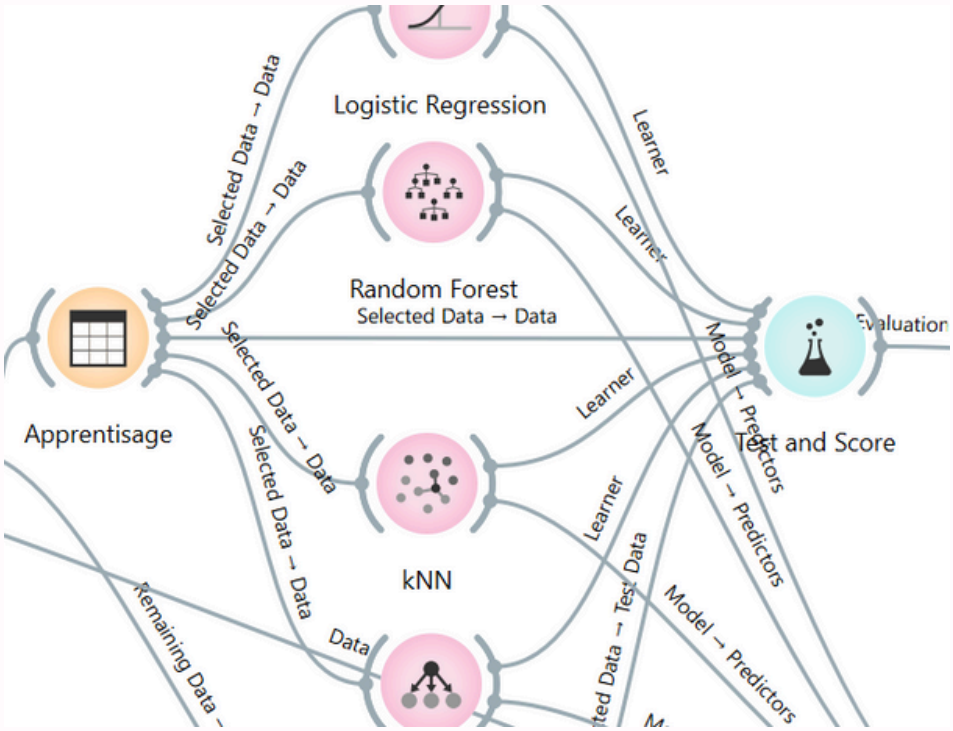


Chaine de traitement avec widget de classification

Nous voulons ici comparer plusieurs familles de modèles dont certains sont très performants pour données mixtes (numerical + categorical), tels que Random Forest. D'autres permettent une interprétation plus fine (Logistic Regression).

2.2 Chaîne de traitement : Classification

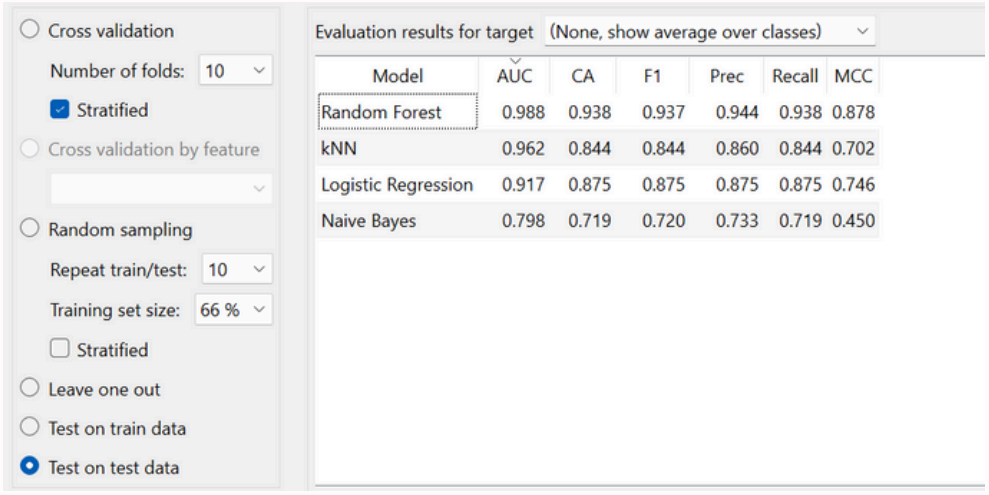
On effectue ensuite une phase d'entrainement ou l'on connecte notre "train" data (échantillon d'apprentisage) puis au widget test and score



Chaine de traitement phase d'entraînement

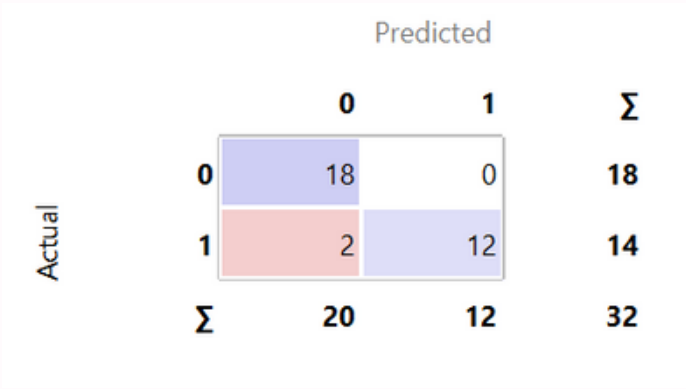
Nous passons ensuite a la phase de test afin de comparer quel modèle est le plus efficace, grâce au widget Test & Score qui calcule automatiquement :

- Accuracy
- F1-score
- Precision
- Recall
- AUC ROC

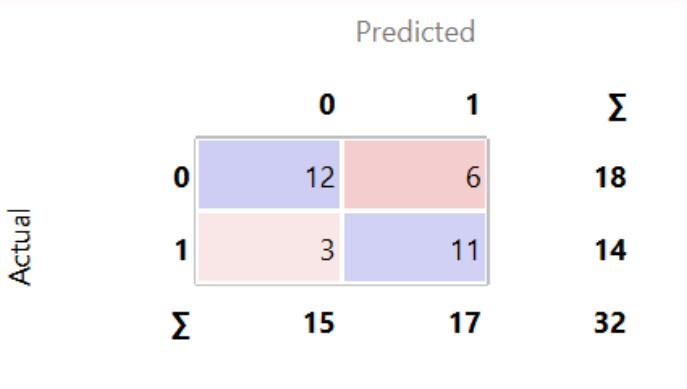


Aperçu de la fenêtre test and score sur le "test" data

Nous pouvons également observer les matrice de confusions afin d'observer le nombre d'erreurs



Matrice de confusion du modèle : Random Forest



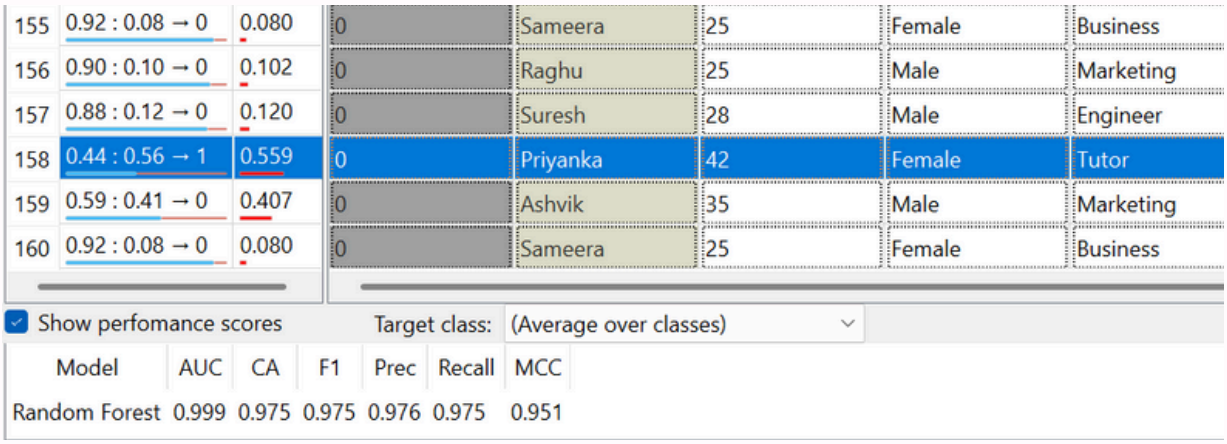
Matrice de confusion du modèle : Naive Bayes

Nous visualisons donc a l'aide du nombre d'erreur de prédictions

- Random Forest est le plus performant → c'est le modèle retenu.
- Naive Bayes est le moins adapté (beaucoup de variables catégorielles corrélées).

On peut enfin analyser les erreurs a l'aide du widget Predictions en le connectant au meilleur modèle observé Random forest dans notre cas. Ce widget permet d'obtenir :

- la prédiction du modèle
- la vraie classe
- les erreurs (mauvaises prédictions)



Fenêtre prédictions avec aperçu d'une l'erreur

2. Apprentissage supervisé

2.3 Interprétation

Les modèles testés montrent des performances variées.
Random Forest est celui qui :

- gère le mieux les variables mixtes (catégorielles + numériques)
- capture les interactions complexes
- fournit la meilleure accuracy

Le modèle atteint une performance correcte (≈90%), ce qui signifie qu'il distingue bien les personnes préférant le télétravail de celles préférant le travail au bureau.

Analyse des erreurs
Les erreurs proviennent souvent des profils "mixtes" :

- personnes très productives mais stressées → prédiction ambigüe
- personnes anti-digital mais appréciant la flexibilité
- personnes ayant beaucoup d'enfants mais préférant tout de même le bureau

Ce qui montre que le choix final dépend d'une combinaison subtile de plusieurs facteurs.

Les résultats montrent que :

- Les individus qui trouvent le télétravail plus productif,
- qui estiment avoir une meilleure qualité de sommeil,
- qui économisent de l'argent,
- et qui disposent d'un bon équilibre vie pro / perso,

sont nettement plus susceptibles de préférer le télétravail (Remote).
À l'inverse :

- ceux qui se sentent moins accompagnés professionnellement,
- ou qui ont un stress plus élevé en télétravail,
- ou qui ne disposent pas d'une connexion suffisante,

ont tendance à préférer le travail au bureau (Office).
Les clusters observés confirment ainsi des tendances sociales bien identifiées dans les études sur le télétravail.